#### 1. Muat Data

Kode ini membagi dataset menjadi tiga bagian: train, validation, dan test. Stratify hanya digunakan sekali agar proporsi kelas (0 dan 1) tetap seimbang tanpa menyebabkan error, karena jumlah data sedikit.

Nilai test\_size diubah dari **0.5** menjadi **0.3** supaya pembagian data tidak terlalu kecil dan setiap subset (train, val, test) tetap memiliki cukup data untuk masing-masing kelas.

# 2. Baseline Model & Pipeline

untuk Pipeline-nya berisi langkah:

- Imputer (median) → mengisi nilai kosong.
- StandardScaler → menstandarkan skala data numerik.
- Logistic Regression → model klasifikasi awal.

Hasil evaluasi menunjukkan F1-score sempurna (1.0)

```
from sklearn.pipeline import Pipeline
from sklearn.compose import ColumnTransformer
from sklearn.preprocessing import StandardScaler
from sklearn.impute import SimpleImputer
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import f1_score, classification_report
num_cols = X_train.select_dtypes(include="number").columns
pre = ColumnTransformer([
    ("num", Pipeline([("imp", SimpleImputer(strategy="median")),
                      ("sc", StandardScaler())]), num_cols),
], remainder="drop")
logreg = LogisticRegression(max_iter=1000, class_weight="balanced", random_state=42)
pipe_lr = Pipeline([("pre", pre), ("clf", logreg)])
pipe_lr.fit(X_train, y_train)
y_val_pred = pipe_lr.predict(X_val)
print("Baseline (LogReg) F1(val):", f1_score(y_val, y_val_pred, average="macro"))
print(classification_report(y_val, y_val_pred, digits=3))
Baseline (LogReg) F1(val): 1.0
              precision recall f1-score support
                 1.000 1.000
1.000 1.000
                                    1.000
1.000
           1
                                      1.000
    accuracy
macro avg 1.000 1.000
weighted avg 1.000 1.000
                                    1.000
1.000
```

## 3. Model Alternatif (Random Forest)

Model alternatif dibuat menggunakan Random Forest dalam pipeline yang sama, dan hasil evaluasi menunjukkan F1-score = 1.0, yang artinya model memprediksi data validasi dengan sangat baik

```
from sklearn.ensemble import RandomForestClassifier

rf = RandomForestClassifier(
    n_estimators=300, max_features="sqrt", class_weight="balanced", random_state=42
)
pipe_rf = Pipeline([("pre", pre), ("clf", rf)])

pipe_rf.fit(X_train, y_train)
y_val_rf = pipe_rf.predict(X_val)
print("RandomForest F1(val):", f1_score(y_val, y_val_rf, average="macro"))
RandomForest F1(val): 1.0
```

### 4. Validasi Silang & Tuning Ringkas

Model Random Forest awalnya belum optimal, jadi dilakukan Cross Validation dan Grid Search untuk mencari pengaturan terbaik (max\_depth dan min\_samples\_split) agar hasil prediksi lebih akurat

```
from sklearn.ensemble import RandomForestClassifier
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.model selection import StratifiedKFold, GridSearchCV
from sklearn.metrics import f1_score
# Pipeline Random Forest
pipe_rf = Pipeline([
    ('scaler', StandardScaler()),
    ('clf', RandomForestClassifier(random_state=42))
# Grid Search + Cross Validation
skf = StratifiedKFold(n_splits=2, shuffle=True, random_state=42)
  "clf__max_depth": [None, 12, 20, 30],
  "clf__min_samples_split": [2, 5, 10]
gs = GridSearchCV(pipe_rf, param_grid=param, cv=skf,
                  scoring="f1_macro", n_jobs=-1, verbose=1)
# Latih model dengan data train
gs.fit(X_train, y_train)
# Tampilkan hasil terbaik
print("Best params:", gs.best params )
print("Best CV F1:", gs.best_score_)
# Uji model terbaik di validation set
best_rf = gs.best_estimator_
y_val_best = best_rf.predict(X_val)
print("Best RF F1(val):", f1_score(y_val, y_val_best, average="macro")
 Fitting 2 folds for each of 12 candidates, totalling 24 fits
 Best params: {'clf__max_depth': None, 'clf__min_samples_split': 2}
 Best CV F1: 0.33333333333333333
 Best RF F1(val): 1.0
```

Meskipun hasil cross=validation masih rendah (0,33), performa model di data validasi sangat baik (1.0). hal ini bisa terjadi karena jumlah data sedikit, sehingga hasil validasi terlihat sangat tinggi

# 5. Evaluasi Akhir (test Set)

Model akhir (Random Forest) memiliki performa sangat baik pada data uji dengan akurasi dan F1-score sempurna (1,0), meskipun hasil ini juga bisa dipengaruhi oleh jumlah data yang sangat sedikit

```
from sklearn.metrics import confusion_matrix, roc_auc_score, precision_recall_curve, roc_cu
 import matplotlib.pyplot as plt
 final_model = best_rf # atau pipe_lr jika baseline lebih baik
 y_test_pred = final_model.predict(X_test)
 print("F1(test):", f1_score(y_test, y_test_pred, average="macro"))
 print(classification_report(y_test, y_test_pred, digits=3))
print("Confusion matrix (test):")
 print(confusion_matrix(y_test, y_test_pred))
 # ROC-AUC (jika ada predict_proba)
 if hasattr(final_model, "predict_proba"):
      y_test_proba = final_model.predict_proba(X_test)[:,1]
         print("ROC-AUC(test):", roc_auc_score(y_test, y_test_proba))
      pass
fpr, tpr, _ = roc_curve(y_test, y_test_proba)
     plt.fignre(); plt.plot(fpr, tpr); plt.xlabel("FPR"); plt.ylabel("TPR"); plt.title("ROC plt.tight_layout(); plt.savefig("roc_test.png", dpi=120)
 F1(test): 1.0
                precision
                              recall f1-score support
                     1.000
                               1.000
                                          1.000
      accuracy
                                           1.000
                     1.000
                                1.000
                                           1.000
     macro avg
 weighted avg
                    1.000
                                1.000
                                           1.000
 Confusion matrix (test):
  [0 1]]
ROC-AUC(test): 1.0
                                            ROC (test)
   1.0
   0.8
   0.6
TPR
   0.4
   0.2
   0.0
                          0.2
                                                                        0.8
          0.0
                                                         0.6
                                                                                        1.0
```